

1.1 从DNN到CNN

(1) 卷积层与汇聚

- 深层神经网络 DNN 中，相邻层的所有神经元之间都有连接，这叫全连接；
卷积神经网络 CNN 中，新增了卷积层(Convolution)与汇聚(Pooling)。
- DNN 的全连接层对应 CNN 的卷积层，汇聚是与激活函数类似的附件：
单个卷积层的结构是：卷积层-激活函数-（汇聚），其中汇聚可省略。

(2) CNN:专攻多维数据

在深度神经网络 DNN 课程的最后一章，使用 DNN 进行了手写数字的识别。但是，图像至少就有二维，向全连接层输入时，需要多维数据拉平为1维数据，这样一来，图像的形状就被忽视了，很多特征是隐藏在空间属性里的，如图1-1。




图 1-1 DNN 的结构

而卷积层可以保持输入数据的维数不变，当输入数据是多维图像时，卷积层会以多维数据的形式接收输入数据，并同样以多维数据的形式输出至下一层，如图1-2。




图 1-2 CNN 的结构

1.2 卷积层

CNN 中的卷积层与 DNN 中的全连接层是平级关系，全连接层中的权重与偏

置即 $y = \omega_1x_1 + \omega_2x_2 + \omega_3x_3 + b$ 中的 ω 与 b ,卷积层中的权重与偏置变得稍微复杂。

1. 内部参数：权重（卷积核kernel）

当输入数据进入卷积层后，输入数据会与卷积核进行卷积运算，如图1-3。




图 1-3 卷积核的运算

图1-3中，输入大小是(4, 4)，滤波器大小是(3, 3)，输出大小是(2, 2)。卷积运算的原理是逐元素乘积后再相加，如图1-4所示。




图 1-4 卷积运算的具体步骤

2. 内部参数：偏置

在卷积运算的过程中也存在偏置，如图1-5。（与输出结果的每个元素相加）




图 1-5 权重与偏置共同作用

3. 外部参数：填充

为了防止经过多个卷积层后图像越卷越小，可以在进行卷积层的处理之前，向输入数据的周围填入固定的数据（比如0），这称为填充（padding）。




图 1-6 填充

图1-6中，对大小为(4, 4)的输入数据应用了幅度为1（1圈）的填充，填充值为0。

4. 外部参数：步幅

使用卷积核的位置间隔被称为步幅（**stride**），之前的例子中步幅都是1，如果将步幅设为2，则如图1-7所示，此时使用滤波器的窗口的间隔变为2。




图 1-7 步幅为 2 的计算方式

综上，增大填充后，输出尺寸会变大；而增大步幅后，输出尺寸会变小。

5. 输入与输出尺寸的关系

假设输入尺寸为 (H, W) ，卷积核的尺寸为 (FH, FW) ，填充为 P ，步幅为 S 。则输出尺寸 (OH, OW) 的计算公式为

$$\begin{cases} OH = \frac{H+2P-FH}{S} + 1 \\ OW = \frac{W+2P-FW}{S} + 1 \end{cases}$$

1.3 多通道

在上一小节讲的卷积层，仅仅针对二维的输入与输出数据（一般是灰度图像），可称之为单通道。但是，彩色图像除了高、长两个维度之外，还有第三个维度：通道（**channel**）。例如，以RGB三原色为基础的彩色图像，其通道方向就有红、黄、蓝三部分，可视为3个单通道二维图像的混合叠加。

一般的，当输入数据是二维时，权重被称为卷积核（**Kernel**）；当输入数据是三维或更高时，权重被称为滤波器（**Filter**）。

1. 多通道输入

对三维数据的卷积操作如图1-8所示，输入数据与滤波器的通道数必须要设为相同的值，可以发现，这种情况下的输出结果降维为了二维（卷积相加）。




图 1-8 多通道下滤波器的运算

将数据和滤波器看作长方体，如图1-9所示。




图 1-9 多通道下的卷积运算

C 、 H 、 W 是固定的顺序，通道数要写在高与宽的前面。

2. 多通道输出

图1-9可看出，仅通过一个卷积层，三维就被降成二维了。大多数时候我们想让三维的特征多经过几个卷积层，因此就需要多通道输出，如图1-10所示。




图 1-10 多通道输出

别忘了，卷积运算中存在偏置，如果进一步追加偏置的加法运算处理，则结果如图1-11所示，每个通道都有一个单独的偏置。




图 1-11 多通道下的偏置

1.4 汇聚（池化）

汇聚（Pooling）仅仅是从一定范围内提取一个特征值，所以不存在要学习的内部参数。一般有平均汇聚与最大值汇聚。

1. 平均汇聚

一个以步幅为2进行 2×2 窗口的平均汇聚，如图1-12所示。




图 1-12 平均汇聚

2. 最大值汇聚

一个以步幅为2进行 2×2 窗口的最大值汇聚，如图1-13所示。




图 1-13 最大值汇聚

汇聚对图像的高 H 和宽 W 进行特征提取，不改变通道数 C' 。

1.5 尺寸变化总结 (重点!!!)

1. 卷积层

现假设卷积层的填充为 P ,步幅为 S ,由

- 输入数据的尺寸是: (C, H, W) 。
- 滤波器的尺寸是: (FN, C, FH, FW) 。
- 输出数据的尺寸是: (FN, OH, OW) 。

可得

$$(C, H, W) * (FN, C, FH, FW) \rightarrow (FN, OH, OW)$$
$$\begin{cases} OH = \frac{H+2P-FH}{S} + 1 \\ OW = \frac{W+2P-FW}{S} + 1 \end{cases}$$

注: FN 为卷积核 (滤波器) 的个数, OH 、 OW 可以计算得出。

2. 汇聚

现假设汇聚的步幅为 S ,由

- 输入数据的尺寸是: (C, H, W) 。
- 输出数据的尺寸是: (C, OH, OW) 。

可得

$$(C, H, W) \rightarrow (C, OH, OW)$$
$$\begin{cases} OH = H / S \\ OW = W / S \end{cases}$$